



Penerapan Machine Learning sebagai Instrumen Penegakan Etika Komunikasi Digital dalam Memitigasi Penyebaran Berita Bohong

Abisena Rais^a, Evy Nurmiati^b

^aSistem Informasi, Fakultas Sains Dan Teknologi, Universitas Islam Negeri Syarif Hidayatullah Jakarta, abisena.rais24@mhs.uinjkt.ac.id

^bSistem Informasi, Fakultas Sains Dan Teknologi, Universitas Islam Negeri Syarif Hidayatullah Jakarta, evy.nurmiati@uinjkt.ac.id

Abstract

The rapid spread of disinformation in the digital era poses a systemic threat to communication ethics, overwhelming manual verification capacities. This study aims to develop and evaluate an automatic text classification model using Machine Learning as a preventive instrument to mitigate fake news and uphold public information rights. Employing a quantitative experimental approach, the study compared five classification algorithms—Logistic Regression, Multinomial Naive Bayes, Linear SVC, Random Forest, and Passive Aggressive—using TF-IDF vectorization on a dataset of 6,335 news articles. Model evaluation prioritized the F1-Score and False Positive metrics to address ethical risks. The results demonstrated that the Linear Support Vector Classification (Linear SVC) outperformed other models, achieving the highest F1-Score of 93.67% and an accuracy of 93.76%. Crucially, the Linear SVC model recorded a minimal False Positive rate, misclassifying only 30 fake articles. This indicates its reliability and ethical accountability as an algorithmic filter. The study concludes that Linear SVC is highly effective for fake news mitigation, though human digital literacy remains the ultimate defense.

Keywords: Digital Ethics, Disinformation, Fake News, Linear SVC, Machine Learning

Abstract

Penyebaran disinformasi yang masif di era digital mengancam etika komunikasi dan melampaui batas verifikasi manual manusia. Penelitian ini bertujuan mengembangkan model klasifikasi teks otomatis menggunakan Machine Learning sebagai instrumen preventif mitigasi berita bohong guna melindungi hak informasi publik. Menggunakan pendekatan kuantitatif eksperimental, lima algoritma dibandingkan: Logistic Regression, Multinomial Naive Bayes, Linear SVC, Random Forest, dan Passive Aggressive dengan ekstraksi fitur TF-IDF pada 6.335 data artikel berita. Evaluasi model difokuskan pada F1-Score dan nilai False Positive untuk meminimalisasi risiko etis. Hasil eksperimen membuktikan algoritma Linear SVC sebagai model terbaik dengan F1-Score 93,67% dan akurasi 93,76%. Model ini terbukti aman secara etis dengan tingkat False Positive yang sangat rendah (hanya 30 kesalahan klasifikasi). Kesimpulannya, Linear SVC sangat efektif diimplementasikan sebagai filter disinformasi, meskipun literasi digital manusia tetap menjadi pertahanan utama di ruang siber.

Kata Kunci: Berita Bohong, Disinformasi, Etika Digital, Linear SVC, Machine Learning

This work is licensed under Creative Commons Attribution License 4.0 CC-BY International license



PENDAHULUAN

Perkembangan pesat teknologi informasi dan komunikasi di era digital telah mendisrupsi secara fundamental bagaimana masyarakat memproduksi dan mengonsumsi informasi. Kehadiran media sosial dan platform digital mempercepat aliran data tanpa batas ruang dan waktu, namun di sisi lain memunculkan kerentanan sistemik terhadap penyebaran disinformasi atau berita bohong (hoaks). Fenomena berita bohong tidak hanya mendistorsi kebenaran faktual, tetapi juga memanipulasi opini publik dengan kecepatan eksponensial yang jauh melampaui kemampuan verifikasi manual manusia (Allcott & Gentzkow, 2017). Dari sudut pandang etika komunikasi digital, penyebaran informasi palsu secara sengaja merupakan pelanggaran berat terhadap hak asasi masyarakat untuk mendapatkan informasi yang benar dan valid. Etika komunikasi menuntut adanya tanggung jawab moral dan integritas dalam setiap transmisi informasi di ruang publik maya (Floridi, 2018).

Mengatasi darurat disinformasi ini tidak dapat diselesaikan hanya dengan mengandalkan regulasi hukum atau pemblokiran situs semata, melainkan membutuhkan instrumen preventif yang berakar pada kesadaran etika dan literasi digital. Kesadaran akan etika digital (*digital ethics*) merupakan salah satu dimensi fundamental yang harus ditanamkan dan dibiasakan sejak dini di lingkungan pendidikan, agar individu memiliki insting untuk memfilter informasi secara kritis di tengah masifnya paparan teknologi (Novenra & Sapta, 2025). Terlebih lagi, masifnya penggunaan *Artificial Intelligence* (AI) dewasa ini juga terbukti memberikan dampak signifikan terhadap dinamika kemampuan berpikir kritis individu (Fiani et al., 2025). Kendati demikian, ketika volume data harian yang diproduksi mencapai skala *big data*, literasi manusia secara kognitif akan mengalami kewalahan (*information overload*). Oleh karena itu, diperlukan intervensi teknologi komputasi yang dapat bertindak secara otonom sebagai "filter etis" untuk membantu masyarakat menyaring dan memverifikasi informasi sebelum terdistribusi lebih luas.



Berdasarkan tinjauan pustaka, pendekatan *Machine Learning* (ML) saat ini dipandang sebagai metode komputasi paling mutakhir dan terukur dalam mengidentifikasi pola penyebaran berita palsu (Shu et al., 2017). Banyak penelitian sebelumnya telah mengeksplorasi penggunaan *Natural Language Processing* (NLP) untuk menganalisis sentimen dan struktur leksikal teks berita. Namun, terdapat kesenjangan (*research gap*) dalam literatur saat ini, di mana mayoritas penelitian murni berfokus pada optimasi metrik akurasi algoritma tanpa menganalisis esensi teknologinya sebagai instrumen penegak etika komunikasi. Belum banyak kajian yang memposisikan model klasifikasi kecerdasan buatan sebagai alat bantu moral yang dirancang secara spesifik untuk memitigasi dampak buruk hoaks demi melindungi hak kebenaran informasi publik.

Untuk menjembatani kesenjangan tersebut, penelitian ini mengajukan penerapan algoritma *Machine Learning* menggunakan integrasi metode ekstraksi fitur *Term Frequency-Inverse Document Frequency* (TF-IDF) dan studi komparasi algoritma klasifikasi (Kowsari et al., 2019). Pendekatan komparatif ini dipilih bukan hanya karena efisiensi komputasinya, tetapi juga karena tingkat transparansi matematisnya yang relatif tinggi dibandingkan algoritma *Deep Learning* yang bersifat *black-box*. Transparansi koefisien pembobotan kata memungkinkan keputusan pelabelan berita untuk dilacak, sehingga model ini dapat dipertanggungjawabkan secara etis dan tidak bias secara membabi buta. TF-IDF bertugas menyeleksi kosakata jurnalistik yang paling representatif, sementara algoritma klasifikasi menghitung probabilitas kebohongan artikel tersebut.

Berdasarkan rasionalisasi dan urgensi permasalahan di atas, penelitian ini bertujuan untuk merancang, melatih, dan menguji efektivitas model klasifikasi teks otomatis sebagai solusi preventif dalam menyaring berita bohong. Hipotesis yang diajukan dalam penelitian ini adalah bahwa algoritma *Machine Learning* berbasis pemrosesan bahasa alami mampu mencapai tingkat akurasi klasifikasi yang signifikan, sehingga sistem ini sangat layak diimplementasikan sebagai instrumen objektif yang memfasilitasi penegakan etika komunikasi digital di tengah masyarakat.

METODE PENELITIAN


Penelitian ini menggunakan pendekatan kuantitatif dengan metode eksperimental (*experimental research*) berbasis komputasional. Pendekatan ini dipilih karena penelitian bertujuan untuk memanipulasi dan memproses data teks ke dalam bentuk numerik guna membandingkan performa berbagai algoritma *Machine Learning* secara terukur dan empiris. Dalam ranah ilmu data dan kecerdasan buatan, desain eksperimental kuantitatif merupakan kerangka metodologi yang paling optimal untuk menguji efektivitas model komputasi secara objektif, di mana variabel algoritma dikontrol dan kinerjanya dievaluasi menggunakan metrik statistik baku (Sarker, 2021). Ruang lingkup objek penelitian difokuskan pada teks berita berbahasa Inggris yang diklasifikasikan ke dalam polaritas biner, yaitu berita bohong (*fake*) dan berita asli (*real*). Tempat pelaksanaan eksperimen dilakukan secara virtual menggunakan lingkungan komputasi awan (Google Colaboratory) guna memfasilitasi kebutuhan pemrosesan bahasa alami (*Natural Language Processing*) secara efisien. Adapun bahan dan alat utama yang digunakan mencakup bahasa pemrograman Python, pustaka *Scikit-Learn* untuk pemodelan algoritma, serta *Pandas* untuk manipulasi struktur data.

Teknik pengumpulan data yang diterapkan adalah pengumpulan data sekunder. Dataset yang digunakan diunduh dari repositori publik Kaggle yang memuat kompilasi teks berita dengan pelabelan yang telah tervalidasi. Dataset ini berukuran total 6.335 baris data (entri) yang sepenuhnya valid dan tidak memiliki nilai kosong (*non-null*). Karakteristik dan struktur dimensi data yang menjadi bahan baku eksperimen dapat dilihat secara detail pada Tabel 1.

Tabel 1. Struktur dan Dimensi Dataset Berita

Kolom	Tipe Data	Keterangan Operasional
Unnamed: 0	int64	Merupakan indeks numerik sekuensial bawaan dari dataset mentah.
title	object	Memuat untaian karakter (string) yang merepresentasikan judul artikel.
text	object	Memuat isi teks berita secara utuh (full text) sebagai fitur utama NLP.
label	object	Kelas target klasifikasi biner untuk membedakan antara berita Fake dan Real.

Adapun rancangan kegiatan dan prosedur pengembangan model divisualisasikan melalui diagram alir penelitian pada Gambar 1 berikut.



Gambar 1. Diagram Alir Tahapan Penelitian dan Eksperimen Algoritma

Berdasarkan Gambar 1, alur penelitian dieksekusi secara sekuensial. Proses diawali dengan akuisisi data, dilanjutkan ke tahap *Preprocessing Data* yang mencakup pembersihan teks (*data cleaning*), transformasi teks menjadi matriks numerik melalui *TF-IDF Vectorization*, hingga pembagian dataset dengan proporsi 80% data latih dan 20% data uji. Matriks data latih tersebut kemudian didistribusikan ke dalam tahap *Latih Model* untuk dipelajari polanya. Model yang telah terbentuk kemudian diuji secara kuantitatif pada tahap *Evaluasi* menggunakan data uji, yang hasilnya dianalisis untuk menarik kesimpulan objektif.

Pada tahap pelatihan model tersebut, penelitian ini menerapkan studi komparasi menggunakan lima algoritma klasifikasi *Machine Learning* yang dikenal memiliki keandalan tinggi dalam pemrosesan data tekstual. Rincian kelima algoritma beserta karakteristik dasarnya diuraikan pada Tabel 2.

Tabel 2. Algoritma Klasifikasi Machine Learning yang Digunakan

Nama Algoritma	Deskripsi Operasional Singkat
Logistic Regression	Model statistik linier yang mengklasifikasikan data berdasarkan nilai probabilitas biner.
Multinomial Naive Bayes	Model probabilistik berbasis Teorema Bayes yang optimal untuk menghitung frekuensi distribusi kata teks.
Linear SVC (SVM)	Algoritma presisi tinggi yang memisahkan kelas klasifikasi dengan mencari garis batas (<i>hyperplane</i>) paling optimal.
Random Forest	Model ensemble yang menggabungkan banyak struktur pohon keputusan untuk mencegah <i>overfitting</i> pada data.
Passive Aggressive	Algoritma klasifikasi proaktif (<i>online-learning</i>) yang sangat sensitif dan agresif dalam mengoreksi kesalahan prediksinya.

HASIL DAN PEMBAHASAN

Hasil Penelitian

Berdasarkan prosedur eksperimen yang telah dirancang, matriks fitur TF-IDF dari data latih diumpankan ke dalam lima algoritma klasifikasi *Machine Learning*. Model yang telah dilatih kemudian diuji kemampuannya dalam mengklasifikasikan data uji yang belum pernah direpresentasikan sebelumnya (sebanyak 1.267 entri berita). Pengukuran kinerja algoritma tidak hanya bertumpu pada tingkat akurasi (*Accuracy*), melainkan juga memperhitungkan metrik *Precision*, *Recall*, dan *F1-Score*. Dalam konteks klasifikasi teks yang tidak seimbang atau memiliki risiko etis tinggi, *F1-Score* dijadikan sebagai metrik determinan utama karena


metrik ini merepresentasikan rata-rata harmonik yang menyeimbangkan rasio antara presisi dan sensitivitas (Kowsari et al., 2019). Hasil komparasi kuantitatif dari kelima algoritma disajikan pada Tabel 3.

Tabel 3. Perbandingan Kinerja 5 Algoritma Machine Learning

Nama Algoritma	Accuracy	Precision	Recall	F1-Score
Linear SVC (SVM)	0.9376	0.9512	0.9227	0.9367
Passive Aggressive	0.9250	0.9271	0.9227	0.9249
Logistic Regression	0.9179	0.9476	0.8848	0.9151
Random Forest	0.8997	0.9108	0.8864	0.8984
Multinomial Naive Bayes	0.8950	0.9154	0.8706	0.8924

Berdasarkan Tabel 3, hasil eksperimen membuktikan bahwa algoritma **Linear Support Vector Classification (Linear SVC)** merupakan model terbaik dengan capaian *F1-Score* tertinggi sebesar 0.9367 (93,67%) dan *Accuracy* sebesar 0.9376 (93,76%). Linear SVC mengungguli *Passive Aggressive* di posisi kedua dan *Logistic Regression* di posisi ketiga. Keunggulan komparatif ini membuktikan hipotesis teknis bahwa varian *Support Vector Machine* dengan kernel linier sangat optimal dalam menangani data teks berdimensi tinggi (*high-dimensional sparse data*) seperti vektor TF-IDF. Linear SVC mampu menemukan garis pembatas (*hyperplane*) paling tegas yang memisahkan kluster leksikal berita asli dengan kluster berita palsu secara presisi (Kowsari et al., 2019). Sebaliknya, algoritma berbasis pohon keputusan (*Random Forest*) dan probabilitas (*Naive Bayes*) mencatatkan performa terendah (di bawah 90%) karena kesulitan mengelola puluhan ribu dimensi kata kunci yang dihasilkan oleh TF-IDF.

Untuk menelaah secara kritis bagaimana model Linear SVC membuat keputusan prediksinya, analisis dilanjutkan dengan membedah rincian *Classification Report* dan memvisualisasikannya melalui Matriks Kebingungan (*Confusion Matrix*) seperti yang ditunjukkan pada Gambar 2.



Gambar 2. Confusion Matrix Algoritma Linear SVC (Best Model)

Interpretasi mendalam dari Gambar 2 menjabarkan pemetaan 1.267 data uji ke dalam empat kuadran prediksi. Model Linear SVC berhasil memprediksi secara akurat 603 berita bohong (*True Negative*) dan 585 berita asli (*True Positive*). Tingkat keberhasilan yang direpresentasikan oleh 1.188 prediksi benar ini mencerminkan keandalan sistem yang sangat kuat. Namun demikian, telaah dalam penelitian ini juga menyoroti aspek kesalahan prediksi yang memiliki implikasi langsung terhadap etika komunikasi digital. Terdapat 49 berita asli yang disalahartikan oleh sistem sebagai berita bohong (*False Negative*). Meskipun merugikan karena menghambat aliran informasi faktual, metrik ini tidak lebih berbahaya dibandingkan tingkat *False Positive* pada model.

Dari Gambar 2, diketahui bahwa hanya terdapat 30 berita bohong yang lolos dari filter dan diprediksi sebagai berita asli (*False Positive*). Dalam perspektif etika teknologi informasi, *False Positive* adalah metrik



yang paling krusial dan berisiko tinggi. Semakin besar nilai *False Positive*, semakin banyak berita hoaks yang diberi label "Real" oleh sistem, yang secara etis justru menyesatkan masyarakat dan memperburuk sirkulasi disinformasi (Zhou & Zafarani, 2020). Dengan nilai *False Positive* yang sangat minim (hanya 30 dari 1.267 uji coba), Linear SVC terbukti tidak hanya unggul secara matematis, tetapi juga menjadi algoritma yang paling "aman" dan bertanggung jawab secara etis.

Oleh karena itu, implementasi model Linear SVC ini sangat relevan digunakan sebagai instrumen mitigasi. Meskipun kecerdasan buatan telah terbukti mampu menyaring berita dengan presisi tinggi, teknologi ini harus diposisikan sebagai alat bantu verifikasi (sistem pendukung keputusan), bukan sebagai penentu kebenaran mutlak. Hal ini sejalan dengan prinsip etika komunikasi digital yang tetap menempatkan literasi kritis pengguna manusia sebagai lapis pertahanan terakhir dalam memvalidasi kebenaran informasi di ruang publik.

SIMPULAN

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, penelitian ini menyimpulkan bahwa penerapan algoritma *Machine Learning* berbasis *Natural Language Processing* (NLP) sangat efektif digunakan sebagai instrumen preventif dalam memitigasi penyebaran berita bohong. Dari lima algoritma yang dibandingkan, *Linear Support Vector Classification* (Linear SVC) terbukti menjadi model paling optimal dengan capaian akurasi sebesar 93,76% dan *F1-Score* sebesar 93,67%. Lebih dari sekadar pencapaian matematis, model ini berhasil menjawab permasalahan etika komunikasi digital dengan mencatatkan tingkat kesalahan positif palsu (*False Positive*) yang sangat rendah. Hal ini menjamin bahwa sistem beroperasi secara aman dan tidak menyesatkan publik dengan melabelkan disinformasi sebagai berita faktual. Dengan demikian, teknologi komputasi ini terbukti layak diimplementasikan sebagai "filter etis" untuk melindungi hak masyarakat atas kebenaran informasi. Meskipun demikian, sistem kecerdasan buatan ini harus diposisikan sebagai alat bantu verifikasi, di mana literasi digital dan daya kritis manusia tetap menjadi benteng pertahanan paling utama di ruang komunikasi maya.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada Ibu Elvi Fetrina, M.IT., selaku dosen pembimbing, atas dedikasi, arahan, serta bimbingan komprehensif yang telah dicurahkan selama proses penelitian dan penyusunan manuskrip ini. Apresiasi dan ucapan terima kasih juga ditujukan kepada Fakultas Sains dan Teknologi beserta Universitas Islam Negeri Syarif Hidayatullah Jakarta atas dukungan fasilitas dan iklim akademik yang sangat memadai. Tanpa adanya kontribusi, ilmu, dan dukungan dari berbagai pihak tersebut, penyelesaian artikel ilmiah ini tidak akan dapat terealisasi dengan maksimal.

DAFTAR PUSTAKA

- [1] Allcott, H., & Gentzkow, M., 2017. Social Media and Fake News in the 2016 Election. *Journal of Economic Perspectives*, 31(2), pp.211-36.
- [2] Fiani, F. R., Alim, J. A., & Ulya, Z. (2025). Dampak Penggunaan Artificial Intelligence (AI) terhadap Kemampuan Berpikir Kritis Mahasiswa. *Jurnal Teknologi Pendidikan Dan Pembelajaran* E-ISSN: 3026-6629, 3(2), 260-267.
- [3] Floridi, L., 2018. Soft Ethics, the Governance of the Digital and the General Data Protection Regulation. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 376(2133), p.20180081.
- [4] Kowsari, K., Jafari Meimandi, K., Heidarysafa, M., Mendu, S., Barnes, L., & Brown, D., 2019. Text Classification Algorithms: A Survey. *Information*, 10(4), p.150.
- [5] Novendra, I., & Sapta, A. (2025). Pentingnya Literasi Digital sebagai Keterampilan Fundamental bagi Siswa Sekolah Menengah Pertama di Era Pendidikan 4.0. *Jurnal Teknologi Pendidikan Dan Pembelajaran* E-ISSN: 3026-6629, 3(2), 807-812.
- [6] Sarker, I.H., 2021. *Machine Learning: Algorithms, Real-World Applications and Research Directions*. *SN Computer Science*, 2(3), pp.1-21.
- [7] Shu, K., Sliva, A., Wang, S., Tang, J., & Liu, H., 2017. Fake News Detection on Social Media: A Data Mining Perspective. *ACM SIGKDD Explorations Newsletter*, 19(1), pp.22-36.
- [8] Zhou, X., & Zafarani, R., 2020. A Survey of Fake News: Fundamental Theories, Detection Methods, and Opportunities. *ACM Computing Surveys (CSUR)*, 53(5), pp.1-40.